



پروژه کارگاه تحلیل داده های آماری

۱. مقدمه و هدف پروژه

پروژه پایانی این دوره آموزشی با هدف سنجش و ارزیابی مهارت‌های عملی دانشجویان در پیاده‌سازی فرآیند کامل تحلیل داده، آماده‌سازی، تصویرسازی و برازش مدل‌های رگرسیونی طراحی شده است. در این پروژه، دانشجویان موظف هستند با استفاده از مجموعه داده واقعی تحت عنوان **Energy Consumption Dataset**، به مدل‌سازی آماری و پیش‌بینی میزان مصرف انرژی در ساختمان‌ها بپردازند.

داده‌های مربوط به این پروژه و جزئیات ستون‌های آن از طریق پیوند زیر قابل دریافت است:

<https://www.kaggle.com/datasets/govindaramsriram/energy-consumption-dataset-linear-regression>

۲. تکالیف و ساختار خروجی‌های مورد انتظار

گام اول: تحلیل توصیفی داده‌ها (Descriptive Analysis)

در این بخش باید شناخت اولیه از ساختار داده‌ها ایجاد شود. خروجی‌های مورد انتظار عبارتند از:

- گزارش ابعاد دقیق ماتریس داده‌ها (تعداد نمونه‌ها و ویژگی‌ها).
- مشخص کردن نوع داده‌ای هر یک از ستون‌ها (عددی یا دسته‌ای).
- محاسبه و ارائه شاخص‌های آماری توصیفی شامل میانگین، میانه، واریانس، مقادیر کمینه و بیشینه، و چارک‌های اول و سوم برای تمامی ویژگی‌های عددی.
- ترسیم و تحلیل ماتریس همبستگی متغیرها برای شناسایی روابط خطی اولیه با متغیر هدف.

گام دوم: مدیریت و پیش‌پردازش داده‌های مفقود (Missing Data)

دانشجویان باید وضعیت داده‌های گمشده را بررسی و اصلاح کنند:

- استخراج تعداد و درصد مقادیر مفقود (NaN) در تمام ستون‌های دیتاست.
- ارائه استدلال فنی برای حذف یا نگهداشت ویژگی‌هایی که نرخ مفقودی بالایی دارند.
- پیاده‌سازی متدولوژی‌های استاندارد جایگذاری داده‌ها (مانند استفاده از میانگین، میانه یا روش‌های مبتنی بر همسایگی مانند KNN) برای متغیرهای عددی و استفاده از مدل‌های مجزا برای متغیرهای دسته‌ای.

گام سوم: تحلیل نموداری و اکتشافی (EDA)

تصویرسازی داده‌ها جهت درک شهودی رفتار متغیرها الزامی است:

- رسم نمودار توزیع (مانند هیستوگرام یا نمودار چگالی) برای متغیر پاسخ جهت بررسی وضعیت تقارن و چولگی.
- رسم نمودارهای پراکنش (Scatter Plot) میان متغیرهای مستقل کلیدی و متغیر هدف جهت کشف الگوهای خطی یا غیرخطی.
- استفاده از نمودارهای جعبه‌ای (Box Plot) برای بررسی توزیع مصرف انرژی در سطوح مختلف متغیرهای دسته‌ای و شناسایی داده‌های پرت (Outliers).

گام چهارم: برازش مدل رگرسیون خطی

فاز مدل‌سازی آماری شامل مراحل زیر است:

- تبدیل متغیرهای دسته‌ای به فرمت عددی با استفاده از روش‌های رمزگذاری استاندارد (مانند One-Hot Encoding).
- تقسیم مجموعه داده به دو بخش آموزش (Train) و اعتبارسنجی (Validation) با نسبت مشخص (مانند ۸۰٪ به ۲۰٪).
- برازش مدل رگرسیون خطی چندگانه و استخراج جدول ضرایب مدل و عرض از مبدأ.
- تفسیر دقیق ضرایب استخراج شده و تحلیل جهت و میزان تأثیر هر متغیر بر مصرف انرژی.
- بررسی معناداری آماری ضرایب با استفاده از شاخص p -value در سطح خطای مشخص.

گام پنجم: تحلیل و آزمون فرض باقیمانده‌ها (Residuals)

بررسی صحت فروض کلاسیک رگرسیون برای اعتبارسنجی خروجی اهمیت دارد:

- محاسبه خطای باقیمانده برای هر نمونه از رابطه $e = y - \hat{y}$.
- بررسی فرض نرمال بودن خطاها از طریق رسم نمودار *QQ-Plot* یا هیستوگرام باقیمانده‌ها.
- بررسی فرض هم‌سانی واریانس خطاها از طریق رسم نمودار پراکنش مقادیر پیش‌بینی شده در برابر باقیمانده‌ها و تحلیل الگوهای احتمالی.

گام ششم: ارزیابی روی داده‌های آزمون و گزارش نهایی

سنجش نهایی مدل بر روی داده‌های ندیده باید انجام گیرد:

- ارزیابی عملکرد مدل بر روی بخش داده‌های آزمون (Test Set).
- محاسبه و گزارش معیارهای خطای استاندارد شامل *RMSE*، *MAE* و ضریب تعیین R^2 در قالب جدول خروجی.
- ارائه جمع‌بندی نهایی، معرفی موثرترین متغیرها و ارائه پیشنهادهای کاربردی جهت بهبود مدل در کارهای آینده.